

基于神经网络的知识推理研究综述

张仲伟^{1,2}, 曹 雷¹, 陈希亮¹, 寇大磊^{1,3}, 宋天挺²

1. 中国人民解放军 陆军工程大学 指挥控制工程学院, 南京 210000

2. 中国人民解放军 73671 部队

3. 中国人民解放军 68023 部队

摘 要: 知识推理是知识图谱补全的重要手段, 一直以来都是知识图谱领域的研究热点之一。随着神经网络不断取得新的发展, 其在知识推理中的应用在近几年逐渐得到广泛重视。基于神经网络的知识推理方法具备更强的推理能力和泛化能力, 对知识库中实体、属性、关系和文本信息的利用率更高, 推理效果更好。简要介绍知识图谱及知识图谱补全的相关概念, 阐述知识推理的概念及基本原理, 从语义、结构和辅助存储三个维度展开, 综述当下基于神经网络的知识推理最新研究进展, 总结了基于神经网络的知识推理在理论、算法和应用方面存在的问题和发展方向。

关键词: 知识图谱; 知识推理; 神经网络

文献标志码: A **中图分类号:** TP181 **doi:** 10.3778/j.issn.1002-8331.1901-0358

张仲伟, 曹雷, 陈希亮, 等. 基于神经网络的知识推理研究综述. 计算机工程与应用, 2019, 55(12): 8-19.

ZHANG Zhongwei, CAO Lei, CHEN Xiliang, et al. Survey of knowledge reasoning based on neural network. Computer Engineering and Applications, 2019, 55(12): 8-19.

Survey of Knowledge Reasoning Based on Neural Network

ZHANG Zhongwei^{1,2}, CAO Lei¹, CHEN Xiliang¹, KOU Dalei^{1,3}, SONG Tianting²

1. College of Command & Control Engineering, Army Engineering University of PLA, Nanjing 210000, China

2. Unit 73671 of PLA, China

3. Unit 68023 of PLA, China

Abstract: Knowledge reasoning is an important means of knowledge graph completion and has always been one of the research hotspots in the field of knowledge graph. With the development of neural network, its applications in knowledge reasoning have been paid more and more attention in recent years. The knowledge reasoning methods based on neural network have not only stronger reasoning and generalization abilities, but also higher utilization rates of entities, attributes, relations and text information in the knowledge base. These methods are more effective in reasoning. The relevant concepts of knowledge graph and knowledge graph completion are introduced, the concepts and basic principles of knowledge reasoning are indicated, and then the latest research progresses of the technology of knowledge reasoning based on neural network are reviewed. The existing problems and development directions of knowledge reasoning in the aspect of theory, algorithm and application are summarized.

Key words: knowledge graph; knowledge reasoning; neural network

1 引言

随着互联网技术的不断发展, 海量的数据信息如潮

水般喷涌不止, 其中蕴含了大量有价值的知识。研究人员希望能够找到一种有效的途径来发现、管理和利用知

基金项目: 国防科技重点实验室基金(No.61421010318); 国家自然科学基金(No.61806221)。

作者简介: 张仲伟(1991—), 男, 助理工程师, CCF 会员, 研究领域为知识图谱与深度学习, E-mail: 358532573@qq.com; 曹雷(1965—), 男, 教授, 研究领域为指挥信息系统工程、决策理论与方法; 陈希亮(1985—), 男, 博士研究生, 副教授, 研究领域为深度强化学习与指挥信息系统工程; 寇大磊(1992—), 男, 助理工程师, 研究领域为深度学习与计算机视觉; 宋天挺(1988—), 男, 工程师, 研究领域为知识工程。

收稿日期: 2019-01-24 **修回日期:** 2019-03-06 **文章编号:** 1002-8331(2019)12-0008-12

CNKI 网络出版: 2019-03-25, <http://kns.cnki.net/kcms/detail/11.2127.TP.20190322.1815.006.html>

识,知识图谱由此应运而生。2012年,谷歌公司率先提出了知识图谱(Knowledge Graph)的概念,最初用于智能化谷歌搜索引擎。实际上,知识图谱起源于20世纪中叶提出的语义网(Semantic Network)的概念,本质上是一个具有图数据结构的知识库。

知识图谱的一种形式化的表述是用事实三元组(头实体,关系,尾实体)来记录各种事物及其之间的相互关系,事物可由上述三元组中的“头实体”和“尾实体”表示,事物之间的相互关系即用三元组中的“关系”表示,例如(北京,位于,中国)即是一个事实三元组,其中头实体和尾实体分别为“北京”和“中国”,“位于”是两个实体之间的关系。

在以知识图谱为支撑的人工智能应用中,很多知识对于人类来说是显而易见的,然而,无论多么明显的知识对于机器来说都是非常难以理解的,必须以适当形式存储于知识图谱中才可能被机器调用。传统的数据互联、信息互联已越来越难以应对当今大数据环境下的知识应用需求,因此,人们需要从新的角度思考知识存储、管理、应用的原则和方法,从更高层次上将人类知识转化为机器可理解、可运用的形式——知识图谱,从而在信息互联的基础上实现变革,使知识互联成为可能。

目前,由于大部分开放知识图谱,例如Freebase^[1]、DBpedia^[2]都是由人工或者半自动的方式构建,导致这些知识图谱比较稀疏,大量实体之间隐含的关系没有被充分地挖掘出来。据2014年的统计,在Freebase知识库中,有71%的人没有确切的出生日期,75%的人没有国籍信息^[3]。知识图谱的不完整制约了人工智能领域各类应用的效能发挥,如何将现有知识图谱里的知识补充完整逐渐成为知识图谱领域亟待研究的重要问题之一。

知识图谱补全(Knowledge Graph Completion,KGC)技术的诞生便是为了应对上述问题。知识图谱补全旨在补全知识图谱中不完整的知识^[4],其最主要的方法就是知识推理。知识推理能够利用知识图谱中现有的显性知识来预测图谱中尚未存储的隐性知识,逐步将知识图谱补充完整,因此成为知识图谱的研究热点之一,在垂直搜索、智能问答等诸多应用领域都发挥了重要作用。随着人们在深度学习领域不断取得新的进展,神经网络与知识推理相结合的方法逐渐显现出其强大能力

与广阔前景,得到大量相关领域研究者的关注。本文在简要介绍面向知识图谱的知识推理相关概念的基础上,归纳总结基于神经网络的知识推理研究进展,并探讨了相关问题和下一步研究建议。

2 知识推理简介

国内外诸多研究者对推理的定义不尽相同,Tari^[5]定义知识推理为基于特定的规则和约束,从存在的知识获得新知识的过程。Russell^[6]认为,推理是从原有语句中推导出新的语句。更具体地,Kompridis^[7]将推理定义为多种能力的集合,包括有意识地理解事物的能力,建立和验证事实的能力,运用逻辑的能力以及基于知识改变或验证现有体系的能力。总的来说,知识推理实质上是指利用已有的知识来推断出新的或未知的知识,从而拓展、补充和丰富知识库。

由于知识是通过(头实体,关系,尾实体)的事实三元组的形式存储在知识库中,故知识推理主要是针对三元组中的实体和关系进行,主要包括实体预测和关系预测。其中,实体预测是指利用已有事实的关系及一个实体,推理出另一个实体并由此构成完整三元组,同理,关系预测则是推理给定的头尾实体之间的关系。

知识推理内涵十分丰富,根据侧重点的不同,有多种推理方法,详见图1。官赛萍^[4]提出知识推理可按推理背景的不同分为传统的知识推理和面向知识图谱的知识推理,其中传统的知识推理包括演绎推理与归纳推理、确定性推理与不确定性推理、单调推理与非单调推理、启发式推理与非启发式推理、简单推理与复杂推理等,而面向知识图谱的知识推理依据推理的步骤不同可简要区分为单步推理和多步推理。漆桂林^[8]、徐增林^[9]、刘峤^[10]等人认为,面向知识图谱的知识推理按照推理方法的不同可分为基于逻辑的推理、基于统计的推理和基于图的推理。基于逻辑的推理方式主要指通过一阶谓词逻辑、描述逻辑等利用规则推理出新的实体关系。基于统计的方法主要指通过机器学习的方法从知识图谱中归纳出统计规律从而进行推理。基于图的推理方法主要包括Path Ranking^[11]算法和基于神经网络的方法。Path Ranking算法的基本思想是将知识图谱视为图(以实体为节点,以关系或属性作为边),从源节点(实体)开

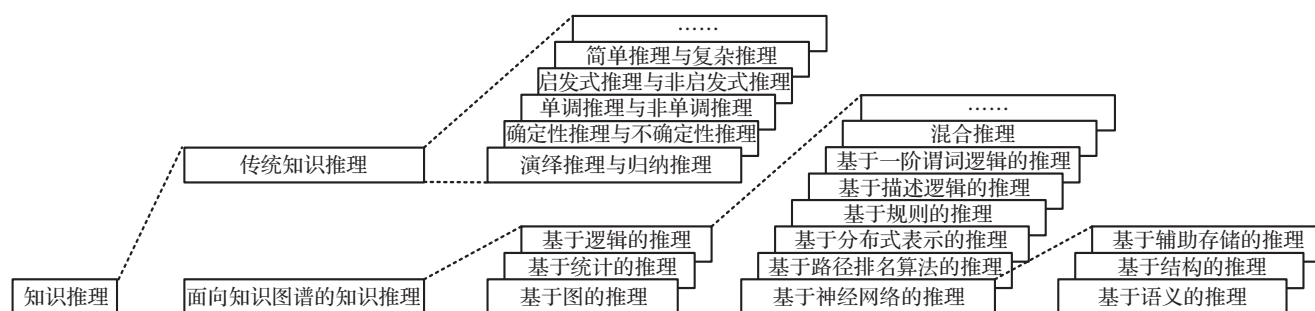


图1 知识推理方法划分

始,在图上执行随机游走,如果能够通过一个路径到达目标节点(另一个实体),则推断源节点和目标节点间可能存在某种关系。基于神经网络的知识推理是一种基于得分函数的方法,利用神经网络建模知识图谱事实三元组,构成得分函数,同时获取三元组中已知元素的向量表示,将之与预测元素或候选元素的向量进行比对,神经网络的输出值即为最终得分^[4]。

在面向知识图谱的知识推理中,较传统的方法,例如基于规则的推理和基于逻辑的推理方法等,其最大优势在于准确率高,但是,该优势的前提条件是能够获取全面的规则与本体约束,而这一条件在现实中很难实现。此外,由于在推理过程中需要额外对规则和本体进行实例化处理,对数据量逐年增长的大规模知识图谱来说计算复杂度过高。相反,神经网络方法具备更高的学习能力、推理能力和泛化能力,不仅能够学习海量的文本语料,缓解大规模知识图谱带来的数据爆炸问题,并且可以直接建模知识图谱事实三元组,降低了计算难度,甚至还能通过合理设计和使用辅助存储单元,在一定程度上模拟人脑推理和思考问题的过程。近几年来,基于神经网络的知识推理吸引了越来越多研究者的目光,本文简介其研究进展,并说明各类推理模型的基本思路与方法。

3 基于神经网络的知识推理

基于神经网络的知识推理其主要思路是利用神经网络的学习能力和泛化能力来建模知识图谱的事实三元组,其中,针对三元组建模并预测三元组元素一般属于单步推理,多步推理则是对多元组构成的连续路径进行建模,对路径首尾实体及其之间的隐含关系等信息进行预测。更具体的,可按照推理依据进一步分为基于语义的推理、基于结构的推理和基于辅助存储的推理。

3.1 基于语义的推理

基于语义的推理建立在挖掘和利用语义信息的基础上,例如实体和关系的名称、描述以及上下文信息等。由于文本中蕴含的潜在语义信息非常丰富,信息之间存在着深刻的语义关联,因此,文本和语义信息自然而然地成为知识推理领域的主要推理依据。本节介绍6种典型的基于语义的推理模型,其中,NTN模型提出一个神经张量网络,并设计了一种长尾实体的新的表示方法;DKRL模型分别通过CBOW和卷积神经网络两种编码器将实体描述添加到实体表示当中;ProjE模型设计一种组合运算符,将输入组合成新的向量,然后投影到候选集上;MT-KGNN模型首次提出利用神经网络建模知识图谱中的属性信息;ConMask模型定义了“开放世界知识图谱补全”,能够将知识库外部新的实体链接到知识图谱中;HNM模型应用于智能问答领域,与传统问答系统基于管道的方法不同,结合了字符及字词级的语义信息,避免了管道方法的错误传播问题。

3.1.1 NTN模型

由于知识图谱的不完整,很多事实并未存储在知识图谱中。为了能够发现不同实体之间隐含的关系,Socher等人^[12]提出一种神经张量网络(Neural Tensor Network, NTN)方法,用双线性张量层代替传统的标准线性神经网络层。通过将数据库中的每个实体表示为向量来获取有关该实体的事实以及它隶属于某种特定关系的概率,通过利用神经张量网络的参数来定义每个关系,将关系表示为三阶张量,并明确地关联两个实体向量,由此能够在使用现有数据库的条件下准确预测其他事实。将关系表示为张量的优点在于能够使得每个切片对应一种不同的语义类型,即一种关系具有多个切片,这样可以更好地建模该关系下不同实体间的不同语义联系^[4]。两个实体处于某种关系的可能性的得分通过如下函数定义:

$$g(e_1, R, e_2) = u_R^T f(e_1^T W_R^{[1:k]} e_2 + V_R \begin{bmatrix} e_1 \\ e_2 \end{bmatrix} + b_R) \quad (1)$$

其中 $f = \tanh$ 是一个标准非线性函数, $W_R^{[1:k]} \in \mathbb{R}^{d \times d \times k}$ 是一个张量, $e_1^T W_R^{[1:k]} e_2$ 是双线性张量积,其结果为 $h \in \mathbb{R}^k$, 每个 h_i 代表一个张量切片 $h_i = e_1^T W_R^{[i]} e_2$, 关系 R 的其他参数参照标准神经网络: $V_R \in \mathbb{R}^{k \times 2d}$, $U \in \mathbb{R}^k$, $b_R \in \mathbb{R}^k$ 。 $g(e_1, R, e_2)$ 函数得分越高,说明实体 e_1 和 e_2 之间处于关系 R 的可能性越高。

此外,常见的原子化的实体表示方法将实体名称视为操作原子,这种表示方法的缺点在于难以解释长尾实体名称的实际语义,例如,原子化的实体表示方法将“apple pie”视为一个操作原子,忽略了该实体中隐含了“apple”和“pie”两个实体的实际语义,并可能误认为“apple pie”实体与“apple”和“pie”两个实体之间没有联系。针对这一问题,NTN模型将长尾实体表示为其构成单词向量的平均值(例如将“apple pie”表示为“apple”和“pie”两个词向量的平均值),充分保留了长尾实体名称中隐含的实体语义。因此,即使没有文本描述信息,NTN模型仍然可以通过对实体名称的拆解来获取一定量的实体描述信息。

然而,仅能挖掘出隐含的关系是不够的,还需要能够将发现的知识库外部新实体链接到知识库。于是,Chen等人^[13]进一步利用NTN神经张量网络的方法,通过预测实体之间额外的真实关系来发现知识库外部的新实体,并将其链接到知识库中,实现知识库的扩展与补全。该模型使用分布式词向量来初始化实体表示,这些词向量来自于类似于维基百科这样的无监督文本语料库。同时该模型使用了一种类似于NTN模型中长尾实体表示方法,即考虑以空格分隔的实体名称的子单元(subunit),能够捕捉语法和语义信息,进而检测数据库之外的实体是否处于某种特定的关系中。该模型的优

点在于无需人为设计任何规则或对其他文本资源进行额外解析。然而,NTN模型建立在张量分解方法的基础上,由于该方法未考虑知识图谱的图形化特点(即知识图谱的多路径结构),推理能力仅限于单步推理,只能预测直接相连的实体间的关系,不能挖掘实体间通过路径传递的深层次关系信息。

3.1.2 DKRL 模型

大部分的知识表示模型如NTN神经张量网络模型、基于转移的TransE^[14]模型、TransH^[15]模型、TransR^[16]模型以及后文介绍的ProjE^[17]投影嵌入模型等,均关注于利用实体和关系名称的嵌入,而在大多数知识图谱中,除了实体与关系的名称之外,还存在着对实体的简明描述,这些描述蕴含了丰富的语义信息却未得到人们的足够重视。Xie等人^[18]认为实体的描述信息能够有助于提高实体表示的准确性,于是提出了基于描述的学习模型(Description-embodied Knowledge Representation Learning, DKRL),利用知识图谱中的实体描述进行实体和关系预测。该模型使用了两种编码器,包括连续词袋(Continuous Bag-Of-Words, CBOW)和深度卷积神经网络(如图2所示)。通过对描述内容的学习,该方法不仅能够获取三元组中的结构信息,而且可以获取实体描述中的关键词和隐藏在语序中的文本信息。DKRL模型的能量函数 E 定义为:

$$E = E_S + E_D \quad (2)$$

其中, E_S 是基于结构表示的能量函数,与TransE^[14]模型的能量函数相同:

$$E_S = \|h_s + r - t_s\| \quad (3)$$

E_D 是基于描述表示的能量函数,定义为:

$$E_D = E_{DD} + E_{DS} + E_{SD} \quad (4)$$

其中 E_{DD} 定义为:

$$E_{DD} = \|h_d + r - t_d\| \quad (5)$$

其中头尾实体均是基于描述的表示。 E_{DS} 和 E_{SD} 分别定义为:

$$E_{DS} = \|h_d + r - t_s\| \quad (6)$$

$$E_{SD} = \|h_s + r - t_d\| \quad (7)$$

其中头尾实体中的一个基于描述的表示,另一个是基于结构的表示。DKRL模型的训练目标是最小化基于边际的评分函数 L :




图2 DKRL模型深度卷积神经网络框架

$$L = \sum_{(h,r,t) \in S} \sum_{(h',r',t') \in S'} [\gamma + d(h+r,t) - d(h'+r',t')]_+ \quad (8)$$

其中 S 是正例三元组集合, S' 是负例集合,负例是指将三元组 (h,r,t) 中的 h 、 r 和 t 中的一个由其他实体或关系替换成错误三元组, γ 是边际超参数,表示正例与负例的最小距离边际, $d()$ 表示计算距离。

DKRL模型的优点是在实体表示过程中结合了实体的文本描述信息,不足在于词向量需要进行预处理,模型对噪音数据比较敏感,需要手动剔除,而且该模型仅与TransE模型进行了对比,可参照性不强。进一步的改进方案可关注于将实体类型、实体属性、关系类型等更多信息与模型相结合。

3.1.3 ProjE 模型

随着知识存储量的不断增大,知识推理模型特征空间日益复杂,参数规模也随之不断增长。Shi等人^[17]通过简化底层模型体系结构,提出一种效果更好而参数规模更小的投影嵌入模型(Embedding Projection, ProjE),其主要方法是将实体预测视为多候选选项排名问题,取其中排名得分最高的候选选项为实体预测结果,如图3所示。

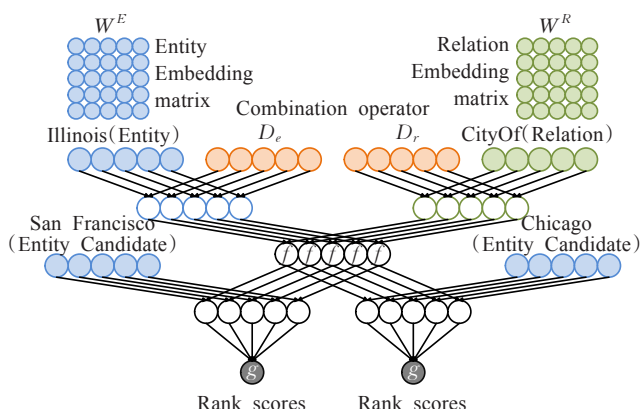


图3 ProjE模型

为了生成排名列表,该方法将每个候选对象投射到一个由输入向量通过预先定义的组合运算符生成的目标向量上,并计算投影相似度。组合运算符定义如下:

$$e \oplus r = D_e e + D_r r + b_c \quad (9)$$

其中 D_e 和 D_r 是 $k \times k$ 对角矩阵,分别作为实体和关系权重, b_c 是组合偏差。该模型通过使用此组合运算符,将嵌入投影函数定义为:

$$h(e,r) = g(W^c f(e \oplus r) + b_p) \quad (10)$$

其中 f 和 g 分别使用sigmoid和tanh(或softmax和tanh)作为激活函数, W^c 是候选实体矩阵, b_p 是投影偏差。 $h(e,r)$ 表示排名分数向量,其中每个元素表示 W^c 中的某个候选实体与组合输入嵌入 $e \oplus r$ 之间的相似性。

总体来看,相对于其他使用转移矩阵的方法,ProjE模型使用组合操作的方式显著减少了参数的数量。该模型设计最初主要针对实体预测任务,后期研究过程中发现通过改变输入,也可以使方法适应关系预测任务。

但是 ProjE 模型关注于通过组合运算符处理实体和关系的嵌入向量,从而产生输出向量,这一流程对词向量预处理的效果存在很大的依赖性,此外,该模型未利用实体描述、属性、关系路径等重要语义信息,推理结果的可解释性略显牵强。

3.1.4 MT-KGNN 模型

目前来看,许多比较先进的知识推理方法普遍关注于利用结构和文本信息,忽略了知识图谱中丰富的属性信息,而例如高度、价格或重量这些基本属性,恰恰能够很好地描述知识图谱中的实体。针对这个问题,Tay 等^[19]提出的多任务神经网络体系结构(Multi-Task Neural Network, MT-KGNN),能够学习实体、关系和属性的表示。该方法设计了两个神经网络,包括关系网络 RelNet (Relation Net) 和属性网络 AttrNet (Attribute Net),其中关系网络 RelNet 对知识图谱的结构和关系进行建模,属性网络 AttrNet 对三元组头尾实体和实体对应的属性进行建模。由于三元组中头实体与尾实体被认为是反对称(antisymmetric)关系,故属性网络 AttrNet 被区分为两个侧面,利用左属性网 AttrNet(left) 获取头实体及其属性,利用右属性网 AttrNet(right) 获取尾实体及其属性。MT-KGNN 模型能够出色完成关系分类和属性值预测任务,结构示意图如图4所示。

关系网络 RelNet 组件定义为:

$$g_{\text{rel}}(e_i, r_k, e_j) = \sigma(\mathbf{w}^T f(\mathbf{W}_d^T [e_i; e_j; r_k]) + b_{\text{rel}}) \quad (11)$$

其中 f 是双曲正切函数 \tanh , \mathbf{w} 和 \mathbf{W}_d 是网络参数。 σ 是 *sigmoid* 函数, b_{rel} 是偏置。为训练关系网络 RelNet, 最小化交叉熵损失函数如下:

$$L_{\text{rel}} = - \sum_{i=1}^N t_i \ln g_{\text{rel}}(\xi_i) + (1 - t_i) \ln (1 - g_{\text{rel}}(\xi_i)) \quad (12)$$

其中 ξ_i 表示大小为 N 的 batch 中第 i 个三元组。 t_i 取 0 到 1 之间的值。

属性网络组件 AttrNet(left) 和 AttrNet(right) 分别定义为:

$$g_h(a_i) = \sigma(\mathbf{u}^T f(\mathbf{B}^T [a_i; e_i]) + b_{z_1}) \quad (13)$$

$$g_t(a_j) = \sigma(\mathbf{y}^T f(\mathbf{C}^T [a_j; e_j]) + b_{z_2}) \quad (14)$$

其中 \mathbf{u} 、 \mathbf{y} 、 \mathbf{B} 、 \mathbf{C} 是属性网络 AttrNet 的参数, b_{z_1} 和 b_{z_2} 是偏置。属性网络 AttrNet(left or right) 的最终输出是一个标量,与关系网络 RelNet 的输出形式相同。不同点在于,关系网络使用交叉熵损失函数,而属性网络希望优化如下均方差损失函数(Mean Squared Error, MSE):

$$\text{MSE}(s, s^*) = \frac{1}{N} \sum_{i=1}^N (s_i - s_i^*)^2 \quad (15)$$

那么,属性网络的全局损失由 AttrNet(left) 和 AttrNet(right) 加和构成,定义如下:

$$L_{\text{attr}} = L_{\text{head}} + L_{\text{tail}} \quad (16)$$

$$L_{\text{head}} = \text{MSE}(g_h(a_i), (a_i)^*) \quad (17)$$

$$L_{\text{tail}} = \text{MSE}(g_t(a_j), (a_j)^*) \quad (18)$$

其中 $(a_i)^*$ 和 $(a_j)^*$ 为真实标签。

MT-KGNN 模型首次提出在推理过程中充分考虑实体属性的重要性,是一个创新思路。而知识图谱的形式化表示通常用(头实体,关系,尾实体)的三元组形式来表达事物的属性以及事物之间的语义关系,其中事物和属性值作为三元组中的实体,属性和关系也均可作为三元组中的关系,因此,在上述模型中,需要预先划分何为关系、何为属性。如果未能明确区分关系与属性,则将产生大量的无效计算并严重影响推理准确性。

3.1.5 ConMask 模型

Shi 等人^[20]将通过利用知识库中已存在的实体和关系进行知识图谱补全定义为“Closed-World KGC”,即“封闭世界知识图谱补全”,此类知识图谱补全方法严重依赖现有知识图谱连接,难以处理知识图谱外部加入的新实体。为了能够应对知识图谱外部的未知新实体,Shi 等人进一步定义了“Open-World KGC”,即“开放世界知识图谱补全”,该方法可以接收知识库外部实体并将其链接到知识图谱。基于上述思想提出 ConMask 模型,该模型主要分为三部分操作:(1)依赖于关系的内容遮蔽(Relationship-dependent content masking):筛选文本信息,删去无关信息,仅留下与任务有关的内容,其

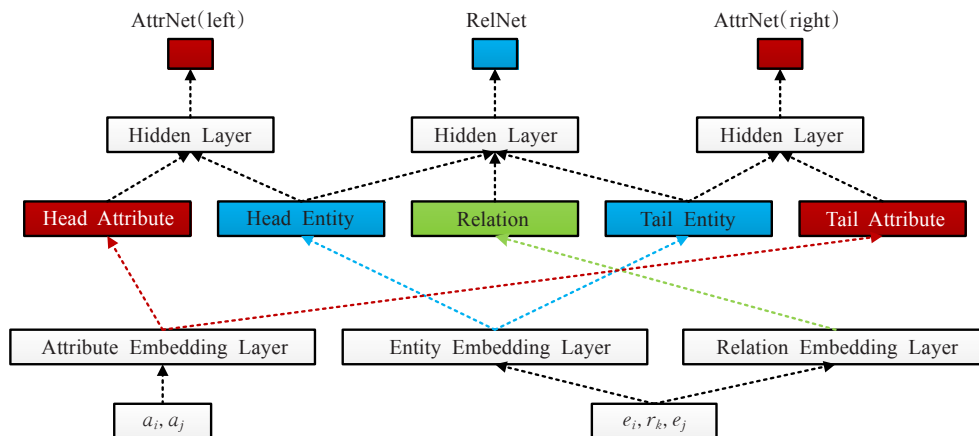


图4 MT-KGNN模型结构图

中利用了注意力机制;(2)目标融合(Target fusion):使用全卷积神经网络从相关文本抽取目标实体的嵌入向量;(3)目标实体解析(Target entity resolution):生成候选实体和抽取实体嵌入之间的相似度排名,相似度最高的认为是最佳结果。

由于ConMask模型从文本中获取信息,因此,当未出现能够准确描述实体或关系的文本时,模型无法获取足够的推理依据,推理效果将大打折扣,该方法难以应对文本信息不足的情形。

3.1.6 HNM模型

目前,智能问答系统逐渐成为人工智能领域研究的热门话题之一,知识图谱已经在基于知识的问答领域显示出其强大的威力^[21]。网络上人们所提问的问题中很大一部分都可以被划分为简单问题,这些问题可以通过从知识图谱中提取一个事实来回答。现有的问答系统通常依赖于各个特定的组件来解决问题的不同子任务(如分割、实体识别、消歧和关系分类等),最终获得正确答案。问答系统的传统方法一般是构建复杂的自然语言处理管道(pipeline),这会导致错误信息沿着管道传播,并且需要人为干预以适应新的领域。

为了避免管道模型复杂的NLP管道结构、产生错误传播的问题,并且希望模型可以在不同的领域重新训练或重用,Denis等人^[22]采用了一种完全不同的方法,他们开发了一个整体神经匹配(Holistic Neural Matching, HNM)模型,学习对主谓词对进行排序,以便检索给定问题的相关事实,然后以端到端的方式回答简单的问题。该模型包含一个嵌套的单词/字符级问题编码器,它能够使用来自问题的字符级和字词级信息来进行实体预测和谓词预测,同时允许处理词汇表之外和罕见的单词问题。也就是说,该模型结合了字符级模型的优点以及单词级模型的丰富语义。尽管该方法仅限于回答简单问题,但这项工作可以作为将来开发更高级的神经问答方法的基础,进一步可以处理更复杂的问题。

3.2 基于结构的推理

基于结构的推理是指利用知识库中三元组内部或相互之间的结构联系进行推理,常用于多步推理问题当中。本节介绍三种基于结构信息进行推理的典型方法,从结构角度可分别定义为基于相邻实体的推理、基于多跳关系的推理和基于组合路径的推理。其中,基于相邻实体的推理利用了与目标实体相邻的关系及实体信息,由图结构GCN网络结合知识图谱有向关系改进而成RGCN模型,使用编码器和解码器对与实体相连的关系进行建模,能够实现实体分类和关系预测;基于多跳关系的推理利用了连续多元组路径上的多跳关系信息,将多跳关系合而为一,推理出一个连接路径首尾实体的“合并关系”;基于组合路径的推理在多跳关系推理的基础上作了改进,综合考虑了多条路径上的关系和中间实

体信息,使预测结果更加准确。

3.2.1 基于相邻实体的推理模型

知识图谱中的实体通过关系与其他实体相连,从单一实体角度看是一种发散的星形图结构,该实体位于结构中心。在这个星形图结构中,有来自中心实体指向相邻实体的关系,也有由相邻实体指向中心实体的关系。为了能够从相邻实体角度学习知识图谱,并将之应用于知识图谱补全,Schlichtkrull等人^[23]从图的角度出发,引入关系图卷积神经网络(Relational Graph Convolutional Networks, R-GCN)从微观上建模星形结构以建模知识图谱。与从前人从文本处理角度考虑知识推理问题不同,Schlichtkrull等人提出的R-GCN网络从结构角度考虑知识推理问题,它由图卷积神经网络(Graph Convolutional Networks, GCN)演化而来,GCN网络适用于处理无向图,而知识图谱中的关系是有向的,作者对此加以改进,设计R-GCN网络,使之能够适应有向关系。R-GCN模型可以看成一组自动编码器,包括一个编码器和一个解码器^[4]。

编码器是一个R-GCN网,将目标实体与知识图谱中的邻居实体进行卷积学习,输入当前实体的相邻关系信息,包括关系类型、关系的方向以及实体自循环的信息,然后输出目标实体的隐性特征向量表示并将其输入解码器。目标实体特征向量的更新过程如图5所示。




图5 RGCN模型实体向量(红色)更新过程

解码器是一个张量分解模型,使用DistMult^[24]作为得分函数,计算头实体向量的转置、关系特定的对角矩阵和尾实体向量的乘积,由此引入关系向量的建模,标记待预测关系。

该模型实验结果不够稳定:在AIFB和AM标准数据集上取得的效果显著,而在MUTAG和BGS数据集上

的实验结果则令人失望,其原因可能与数据集的性质有关。MUTAG是一个分子图数据集,其中的关系类型比较单一,要么表示原子键,要么仅表示某个特性的存在性;BGS是英国地质调查所发布的一个具有层次特征描述的岩石类型数据集,与MUTAG类似,其中的关系仅表示特定特征或特征层次的存在性。针对这一问题,可以尝试的改善方法是引入注意力机制,将归一化常数替换为注意力权重^[23]。

R-GCN网络模型从图的角度首次将GCN网络引入知识推理,思路新颖,在链接预测和实体分类问题上于一些特定数据集上取得了较好的效果。但该方法基于GCN网络的演化设计较为粗糙,针对关系类型较少的数据集处理能力偏弱。此外,该方法缺乏与最新baseline的对比,可参考性有待验证。因此,R-GCN网络模型与其他推理模型相比还不够成熟,仍存在较大改进空间。

3.2.2 基于多跳关系的推理模型

知识图谱中的事实三元组并非相互孤立,很多三元组之间具有连接关系,一个三元组的尾实体可能是另一个三元组的头实体,这样的两个三元组可以构成一个五元组路径,而此时该五元组的头尾实体之间可能隐含了某种可以表示的关系。例如,若存在三元组(A, 父亲, B)与(B, 父亲, C)可知应当存在三元组(A, 祖父, C)。为了预测多元组路径首尾实体间的关系,Arvind等人^[25]提出了一种多跳关系推理方法,使用递归神经网络(Recurrent Neural Network, RNN)在任意长度路径中将关系隐含的语义组合起来。

该方法在每个路径的组合步骤中,利用下一跳关系的嵌入向量,以及表示从起始到目前实体为止的多跳路径的向量,组合成一个输出向量(表示扩展的路径到目前为止),作为下一个步骤的输入。在使用多跳路径之后,RNN在路径的第一个实体和最后一个实体之间输出一个关系向量,该向量包含了整个路径上所有关系的信息。如图6所示,在依次组合了沿着多元组路径“Microsoft(IsBasedIn)Seattle(StateLocatedIn)Washington(CountryLocatedIn)USA”的所有关系向量后,上述方法在头实体“Microsoft”和尾实体“USA”之间产生一个非常接近于“CountryOfHeadquarters”关系的向量。

也就是说,此方法利用了多元组中的全部关系信息,将之依次组合并生成最终头尾实体间的合并关系。然而,考虑到知识图谱中大量的多元组内部并不一定存在顺序语义关联,仅利用多元组路径上的关系信息进行合并推理在语义层面难以解释,并且在计算中容易被路径上不同类型关系的语义差异误导,产生无意义或不可解释的推理结果。

巧合的是,在几乎同一时间,Lin等人^[26]也提出PTransE方法,与上述方法其有着异曲同工之处。PTransE方法也希望建立关系路径的向量表示,参与多元组从头实体到尾实体的翻译过程。Lin认为,这是典型的组合语义问题,需要对路径上所有关系的向量进行语义组合产生路径向量,于是尝试了多种语义组合操作,包括相加、按位相乘和使用循环神经网络。最终结果显示相加的组合操作效果最好。该方法中利用循环神经网络的实验思路与基于多跳关系的推理模型非常相似。

3.2.3 基于组合路径的推理模型

对于知识图谱中多个三元组连接而成的多元组来说,其首尾实体之间可能存在多条路径,换句话说,首尾实体之间可能由若干多元组构成多种不同的路径形式。3.2.2小节中的多跳关系推理方法只使用了该多元组单一路径信息,即利用路径上的关系向量组合计算概率得分,未考虑其他路径,并且没有建模路径上的实体,而是只推理了其中的“合并”关系。为改进前述方法,Das等人^[27]将内容丰富的符号逻辑推理与泛化能力较强的神经网络相结合,训练一个单一的高能力RNN。该模型缓解了路径排序算法(Path Ranking Algorithm, PRA)无法共享参数及参数量大的共性问题,允许跨多个关系类型共享参数进行推理,它利用了实体对之间的路径上所存在的中间实体的信息,并通过将它们表示为带注释类型的函数来缓解实体透明性的问题。该方法使用了注意力机制,充分利用关联的多个路径而不仅仅是针对单个路径进行推理,分别用Top-k、average和LogSumExp方法为每一条路径的相似度评分加上权重,这样就考虑了每一条路径包含的信息,而不仅仅是评分最高的那条。注意,该方法不适合处理较长的文本特征。

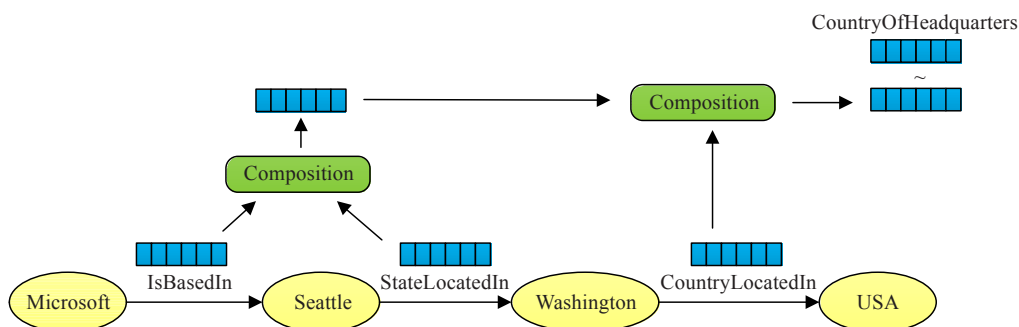


图6 多跳关系推理方法

由于知识图谱中三元组的复杂性和巨大数量,由连续三元组构成的路径和长路径众多,其中存在大量的无效闭环或路径,上述3.2.2小节及3.2.3小节介绍的两种推理模型可归纳为基于路径的推理,其中使用的RNN循环神经网络单元对长路径的记忆能力差,并且长路径容易导致首尾实体之间产生难以解释的语义联系,因此,基于路径的推理方法目前难以适应大规模知识图谱,建议在应用中与基于转移的Trans系列方法相结合以提高推理效果。

3.3 基于辅助存储的推理

基于辅助存储的推理类比为人类大脑对知识的存储和读写,利用共享记忆组件或外部存储矩阵来存储推理所需中间结果或必要信息,模拟了人的推理思考过程。通过辅助存储能够便于推理过程获取隐含信息,提高推理效率。本节介绍两种典型方法,其中,IRN模型共享一个记忆组件,该记忆组件用于存储知识库信息,可以随时由模型读取;DNC模型,通过对共享外部矩阵的读写来模拟人脑对知识记忆的“增、删、改”过程。

3.3.1 IRN模型

为了模仿人脑对知识的存储能力,Shen等人^[28]提出隐性推理网IRN(Implicit Reasoning Nets)模型。该模型设计了一个共享记忆组件来隐式地存储知识库信息,以此模仿人脑对知识的存储。区别于常用推理方法中人工设计推理过程来显性地操纵观察到的三元组,该方法在没有人干预的情况下能够通过共享记忆组件的读取来隐式地学习多步推理过程,模拟了人脑在进行推理判断时读取记忆的过程。该模型在预测过程中需要先后形成多个中间表示,针对每次生成的中间表示,使用一个RNN控制器来判断该中间表示是否已经编码了足够多的信息用于产生输出预测。如果控制器允许,则输出当前预测作为最终结果。否则,控制器获取当前的中间表示并读取共享记忆组件,将两者的信息合并而成一组上下文向量以产生新的中间表示,然后重复执行上述

判断过程,直到控制器允许停止该过程,此时即可输出预测结果。IRN模型框架示意图如图7所示。

该模型的共享记忆组件由一系列向量组成,定义为:

$$M = \{m_i\}_{i=1}^{|M|} \quad (19)$$

其中 m_i 为一个向量, $|M|$ 是共享记忆组件,是一个矩阵。

在训练时,共享记忆组件(在所有训练样本中共享)首先进行随机初始化,然后与控制器共同在训练数据上学习。控制器对过程的判断是通过一个逻辑回归模块 $\text{sigmoid}(W_c s_t + b_c)$ 来估计概率 $P(\text{stop}|s_t)$, 其中权重矩阵 W_c 和偏差向量 b_c 是在训练期间学习得到, s_t 是第 t 步的中间表示。控制器将以概率 $P(\text{stop}|s_t)$ 停止,并调用解码器以产生输出,以概率 $1 - P(\text{stop}|s_t)$ 生成下一步的中间表示 $s_{t+1} = \text{RNN}(s_t, x_t)$, 然后重复上述步骤。迭代该过程最多重复到预定义的最大步骤 T_{\max} 。在测试时,若模型输出预测结果 o_j , 则步骤 j 应具有最大终止概率 $P(\text{stop}|s_j)$ 。

3.3.2 DNC模型

除了能够存储知识,人脑可以对知识进行读写,即不仅能将知识存进脑中,而且也可以调用对知识的记忆,并且在人脑与客观世界的交互过程中不断对记忆的知识进行维护,包括修改错误知识,记忆新的知识,遗忘无用的知识等。受此规律启发,Graves等人^[29]提出一种DNC(Differentiable Neural Computer)模型,该模型与3.3.1小节介绍的IRN模型的区别在于其不仅包含一个LSTM^[30-31](Long Short Term Memory)神经网络控制器和一个存储矩阵,而且该存储矩阵可以选择性地进行读写操作,可以通过迭代修改存储内容(IRN模型的记忆组件只支持读取数据,而不能随时写入或更改)。与传统计算机通过地址获取存储内容不同,DNC存储矩阵通过可微的注意力机制来定义矩阵中位置的分布,这些分布的依据是权重参数,代表着每个位置在读或写中的参与程度。该模型以知识图谱三元组为输入进行训练,

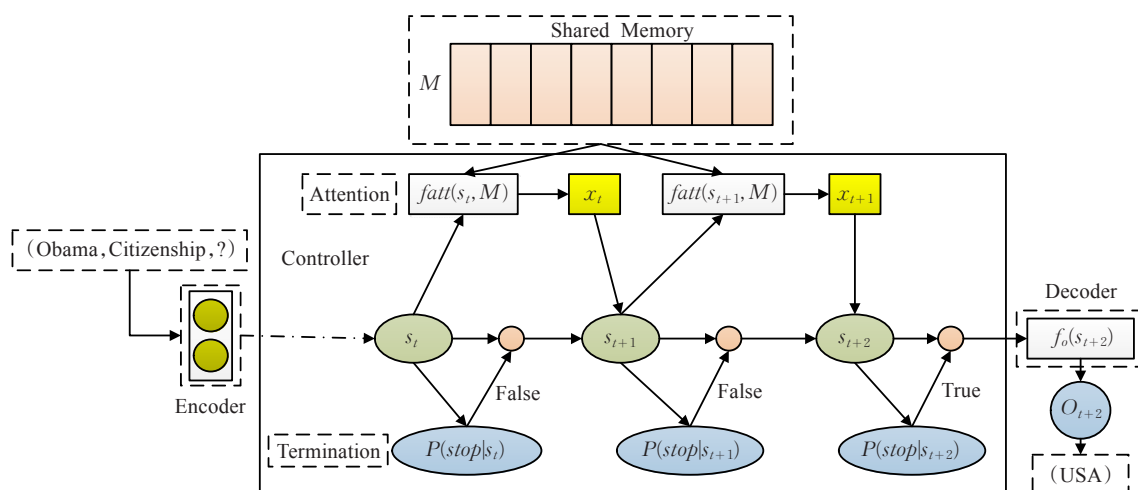


图7 IRN模型框架示意图

由 LSTM 神经网络读写存储矩阵,并不断更新存储矩阵。形象地说,就是模仿了人类通过将新学得的知识存入大脑,更新人脑知识存储,再对记忆的知识进行运用的过程。在测试过程中,只需将待预测的不完整三元组(已删去待预测元素)输入训练好的神经网络中,通过 LSTM 神经网络控制器与存储矩阵的不断交互,确定待预测元素,并输出补全的三元组。

DNC 模型通过对共享外部矩阵的读写来模拟人脑对知识记忆的“增、删、改”过程,此方法存在的问题在于外部存储矩阵所存储信息的可解释性不强,例如,每次与矩阵交互所读取及修改的隐式向量包含哪些内容不明,这些内容包含何种信息也不够清楚。此外,修改知识记忆的依据不详,而且未提出区分修改前后知识正误的判断方法。DNC 模型是对人脑知识记忆的抽象模拟,在人们对大脑的复杂功能和运行机制还未研究透彻的今天,计算机模拟人脑实现类似功能的努力仍处于初步阶段,人脑对知识的处理和应用原理仍有更多复杂机制值得人们模仿与学习。该领域后续研究空间巨大,值得深入探索。

3.4 其他推理方法

面向知识图谱的知识推理一直以来属于 NLP(Natural Language Processing)自然语言处理领域,一些研究者创新地将知识推理拓展到计算机视觉领域,希望能够将推理与视觉信息相结合,解决图像模式识别背后的关系推理问题。例如 Wang 等人^[32]将知识推理与图像识别相结合,探讨了一个有趣的社交关系推理问题。该方法训练了一个图推理模型(Graph Reasoning Model, GRM),由该模型结合门控图神经网络(Gated Graph Neural Network, GGNN^[33])可以对照片中人物的社会关系进行推理。其主要方法是在社交关系数据集 PISC 的基础上生成一个任务关系知识图谱,利用 GRM 根据图片中人物区域的特征来初始化关系节点,然后用预先训练的 Faster-RCNN^[34](一种图像处理方法)探测器搜索图像中的语义对象,并提取其特征,初始化相应的对象节点。之后 GGNN 负责计算节点特征,通过图传播节点消息以充分探索人与上下文对象的交互,并采用图注意力机制自适应地选择信息量最大的节点,以通过测量每个对象节点的重要性来促进识别。图片中出现的不同物品可能对应着不同的社交关系,比如:当识别出烤箱,对应于家庭关系的概率就比较大,当识别出键盘,那么就更容易判定为职场关系。

为了更直观得认识本章介绍各类基于神经网络的推理模型,表 1 给出了典型模型的简介及优缺点对比。

4 知识推理应用前景

知识推理不仅能够用于补全知识图谱,在现实中也

广泛应用于智能医疗、问答搜索、金融评估等领域,并且取得了一定效果。知识图谱最初设计背景是应用于搜索引擎领域,目前利用知识图谱支撑的搜索引擎基本能够从语义层面理解用户意图,改进搜索质量,大幅地提升和优化了搜索体验。此外,很多金融领域公司也构建了金融知识库以进行碎片化金融数据的集成与管理,并通过知识推理等手段辅助金融专家进行风险控制、欺诈识别等。生物医疗专家通过集成和分析大规模的生物医学知识图谱,能够利用知识推理进行药物发现、潜在靶点识别等多种任务。

4.1 智能医疗

目前国内外医学知识图谱的研究都取得了很大进展,国内主要有康夫子“医疗大脑”和百度“医疗大脑”,二者重点关注于对 3 000 余种常见病的建模;国外比较著名的是 IBM Watson,用来辅助医生在肿瘤领域进行诊疗决策。国内“医疗大脑”尚处于深入研究阶段,尚未开展商业应用,而在国外则已将基于知识图谱的智能医疗应用于少数顶尖医疗机构,其肿瘤诊断准确率最高可达 96%。例如全世界最有名的癌症治疗中心——安德森癌症中心通过整合大量医疗文献和书籍以及各种电子病历来获取海量高质量的医疗知识,并基于这些知识为医护人员提供辅助临床决策和用药安全提醒等服务,取得了巨大成功。

知识图谱是智能医疗的底层核心,而基于知识图谱的知识推理是疾病诊断过程的基础。通过借助医学知识图谱,知识推理能够帮助医生根据病患的身体症状及近期摄入或接触物品等完成病患数据搜集与疾病诊断,从而为医生制定决策参考,降低医疗差错率。

近年来新兴的智能医疗行业主要是通过机器学习技术从海量医疗数据中收集信息构建知识图谱,然后根据历史诊疗的经验数据自动学习诊断逻辑进而实现诊疗推理。构建医疗知识图谱的数据主要来自于三个方面,一是权威医学文献,例如医学数据、诊疗指南和相关论文等;二是各大医院的历史病历数据;三是互联网科普咨询及医患交互问答数据。前两者用于构建医疗知识图谱,而互联网数据则主要用来将患者口语化的病情或症状描述与专业术语相对应,减少数据冗余,提高推理精度。

4.2 金融反欺诈

知识图谱作为实体与关系构成的三元组集合,对关系的表达能力极强,推广到人物知识图谱中,能够展现清晰的人物关系网,这对挖掘目标人员的社交群体有非常大的帮助。基于此特点,知识图谱被应用于金融反欺诈领域,利用知识推理来预测某客户是否通过复杂关系网与金融黑名单中的人员有直接或间接的社交关系,以便进一步采取适当应对措施,规避潜在金融风险。

另一方面,知识推理可利用目标人员的相关知识网

表1 基于神经网络的知识推理典型模型汇总表

方法	方法简要描述	方法优点	方法不足	适用场景
NTN	1. 提出神经张量网络,用关系张量的不同切片对应不同语义类型 2. 提出一种新的长尾实体表示方法	更好地建模某关系对应不同实体对之间的不同语义联系	无法推理知识库外的隐含关系	适用于处理长尾实体,并能够应对多语义关系
DKRL	通过 CBOW 和深度卷积神经网络编码实体描述信息	充分利用了实体描述携带的语义信息	缺乏对文本描述中的噪音信息的有效处理	适用于携带大量实体描述的知识图谱
ProjE	将候选对象投射到由输入向量通过预先定义的组合运算符生成的目标向量上,并计算投影相似度	共享参数,参数量明显减少	仅用于单步推理,组合运算符可解释性不强	适用于大规模知识图谱
MT-GNN	设计关系网络和属性网络,建模知识图谱的结构、关系和属性	首次将实体属性利用到推理中	知识图谱实体属性信息不全对推理效果影响很大	适用于实体属性充足并已结构化表示的知识图谱
ConMask	1. 定义“Closed-World KGC”和“Open-World KGC” 2. 通过全卷积神经网络有选择地利用文本信息抽取目标实体的嵌入向量并与候选对象比对	能够应对知识图谱外部的未知新实体	对实体描述中关键信息选取的准确性有待提高	适用于动态知识图谱的知识推理,能够应对新兴实体
HNM	使用字级编码器编码问题,并对主语和谓词排序	能够应对新的和罕见的开放世界问题	只能处理简单问题,难以应对如逻辑推理等复杂问题	适用于动态知识图谱,能够支撑简单的问答
相邻实体推理	设计关系图卷积神经网络编码实体与邻居实体及其之间关系	首次将图网络方法引入知识推理	模型粗糙,实验结果不稳定,需要进一步改进	适用于关系稠密的知识图谱,需要充足的实体关系类型
多跳关系推理	利用 RNN 预测连续三元组构成路径上的首尾实体间的关系	能够针对五元组、七元组等短路径推理首尾节点关系	输入未结合路径上的实体,不能处理较长路径,不适用大规模知识图谱	适用于中小规模知识图谱
组合路径推理	推理多元组路径首尾实体关系时利用了其他相同首尾节点的路径,并考虑了路径上中间实体的信息	能够共享参数,利用的数据信息量更大	不能处理较长路径,不适用大规模知识图谱	
IRN	共享一个记忆组件,该记忆组件用于存储知识库信息,可以随时由模型读取	能够模拟人脑,隐式地学习多步推理过程	对非结构化数据的处理能力弱,尚难处理自然语言查询问题	适用于高质量低噪知识图谱
DNC	通过对共享外部矩阵的读写来模拟人脑对知识记忆的“增、删、改”过程	不仅能够存储知识,还可以对记忆内容进行修改	修改知识记忆的依据不足,可解释性不强,无法区分修改前后知识的正误	

络,搜集其真实背景属性-值对,将目标人员真实的属性-值对和该人员在办理金融手续时出示的个人信息进行比对,检查是否一致。若存在明显差异则说明该人员涉嫌刻意隐瞒了真实信息。除此之外,若某人在金融知识图谱中被记入黑名单,说明该人可能存在群体性欺诈隐患,因此,与其具有直接社交往来的其他人员也将被标注为高风险人员。

国内在金融反欺诈领域发展较成功的是“拍拍贷”信用贷款平台,该平台自主研发“明镜”和“魔镜”系统在金融业内颇有声誉。“明镜”系统用于全流程反欺诈调查的风险识别,拥有由知识图谱支撑的可视化关系网络,在运行过程中提高拍拍贷反欺诈调查效能70%;“魔镜”系统主要用于风控,该系统基于百亿条数据积累,可结合知识推理和机器学习等技术预测每一笔借款风险评级,极大提高了贷款审核效率。此外,拍拍贷平台还将知识图谱技术运用于智能催收业务,对逾期3天以内的

客户催回收款率可达人工方法的90%以上,大大节约了人力成本。

4.3 智能问答与搜索

目前网络上的智能问答与搜索引擎大多是“关键词识别+数据库搜索”的方法,对于市面上很多所谓的智能问答机器人来说,其之所以能够回答人们提出的一部分问题,是因为在其庞大的数据库中已经将问题预置其中,只要提问者提出类似的问题,智能问答机器人均能通过关键词搜索找出相应答案。

然而知识库无法存储近乎无限规模的提问,而且也并不是所有问题都能找到显性的正确答案。知识推理的任务就是能够利用已有的知识和信息,间接推理出隐含知识。例如假设某知识库中存储有三元组(刘欢,母语,汉语)和三元组(中国,语种,汉语)而没有刘欢的国籍信息,那么知识推理能够根据上述事实推断出(刘欢,国籍,中国)这样的正确结果。

目前国内外比较成熟的智能问答搜索系统,主要包括国外的苹果 Siri、亚马逊的 Alexa 以及 IBM Watson 等,以及国内已投向应用的淘宝小蜜和百度度秘,其中淘宝小蜜系统下分多个子系统,包括阿里小蜜、阿里店小蜜、AliGenius 等,能够针对不同领域知识独立提供服务,知识推理技术在其订单预测、问题预测、智能推荐等功能中发挥了极其重要的作用。据阿里巴巴公司内部统计数据显示,2018 年淘宝网双 11 购物节期间,智能客服机器人阿里小蜜承载了平台近 98% 的服务请求量,相当于 10 万名人工客服的工作量;商家智能助手阿里店小蜜,承载了 3.5 亿次对话,相当于 58.6 万名客服的对话能力;AliGenius 智能售后工作台,通过自动化操作,帮商家节约了共计 16.2 万名客服人力。

4.4 军事辅助决策

新形势下的军事斗争逐渐向基于网络信息体系的联合作战偏移,该作战形式需要各军兵种密切协同,其中智能化指挥控制是必不可少的一环。智能化指挥控制的主要作用是为战场指挥员提供决策辅助,其智能化水平与知识运用能力紧密相关。在此需求下,迫切需要建立军事知识图谱,其中包括战场环境知识图谱、战场情报知识图谱、联勤保障知识图谱、战斗要素知识图谱等诸多分图谱。

知识推理在军事知识图谱中的应用前景广泛,除了能够自动化补全军事图谱中的信息缺失,支持垂直搜索以外,能够结合战场环境和战斗要素知识推理特定场景下最佳攻防战术,利用战场情报知识实现潜在敌情超前预警,通过联勤保障知识预测保障需求或战斗消耗。知识推理使得信息处理速度更快更全,能够全面利用人们难以发现的细微线索和事实挖掘背后的隐藏联系,大幅减轻作战指挥人员工作量,提供更周全的决策建议。

5 总结与展望

近年来国内外涌现出多种基于神经网络的知识推理方法,取得了一定进展的同时仍然存在不同程度的问题。本章简要描述当前研究进展的几个瓶颈问题,然后有针对性地提出下一步研究建议,最后展望基于神经网络的知识推理研究发展前景。

5.1 存在的几个问题

(1)神经网络的可解释性问题。神经网络模仿人的大脑,采用自适应算法,能够总结规律,完成运算、推理、识别等任务,并且容错能力高,但是,神经网络具备黑盒特性,该技术的可解释性问题仍未得到有效解决,人们难以表达神经网络得出结论的原理或原因。因此使得基于该技术的知识推理在与其他方法比较时难以获得更好理论支撑。

(2)知识推理的共性问题。知识推理对大规模训练数据的依赖性很高,并且难以处理开放世界推理的问

题。目前公开的知识库数据质量不高且数据规范不统一,而基于神经网络的知识推理在训练中对噪音非常敏感,错误的或模棱两可的数据将导致学习偏差,此类问题在基于分布式表示学习与神经网络相结合的混合推理过程中尤为明显。开放世界推理难题意味着目前的知识推理还难以应对知识图谱外部的新事物和新知识,交互能力不足,应用场景主要限定于利用知识图谱内部已有信息进行补全降噪等,功能拓展受到限制。

(3)推理依据的利用问题。研究中发现,当前大部分研究者将目光聚集于基于语义的推理方法,重点利用了实体和关系的名称、描述、类别等信息,还有少部分人关注于利用结构关系进行推理。实际上,知识图谱内存在大量的属性信息,能够作为实体和关系的标签,是十分重要的推理依据,而这些信息尚未引起广泛重视。

5.2 下一步研究建议

(1)尝试多种方法交叉融合。针对神经网络解释性差的问题,可以考虑将其他推理方法与神经网络方法相结合来作为突破口,例如可以将神经网络的学习、泛化能力与基于规则推理的可解释性结合,与基于分布式表示推理的表示能力结合等,实现优势互补。现有的融合方法大部分是利用神经网络搭建上层学习框架,底层的表示与解释则通过规则与分布式表示来完成。如何科学自然地实现方法融合,是值得考虑的难点。

(2)探索更好的开放域实体链接方法。通过开放域实体链接,能够打通封闭世界知识图谱与开放世界之间的通道,使得新的实体和关系以及新的知识能够更便捷地添加到知识图谱中,将其与知识推理结合能够更好地应对开放世界推理问题。目前封闭域实体链接研究进展较成熟,有的能达到应用水平,而面向开放域的实体链接仍有待进一步的研究和发展。

(3)创新利用推理依据。知识图谱内含信息丰富,既有语义信息,如实体名称、关系名称、实体描述、属性能信息,又包含大量的结构信息,如三元组、多元组、路径等,这些与事实三元组紧密相关的信息都可以作为推理的依据。因此,一方面不妨尝试借鉴 DKRL、MT-KGNN 等模型的方法,探索通过卷积神经网络利用实体属性进行推理的新渠道;另一方面,可以大胆探索对不同信息的融合利用,例如借鉴本文 3.2.3 小节中基于组合路径推理的方法,在推理过程中充分利用实体、关系、路径等多种信息,信息量更大,推理效果更好。

(4)建模人脑推理过程。本文介绍的 IRN 模型及 DNC 模型均模拟了对人脑记忆知识、维护知识的过程,并取得了一定成果,是非常有意义的尝试。人脑具有极强的学习和推理能力,并且能够基于小样本数据学得大量有效知识。因此可在现有方法的基础上,在人脑获取知识、利用知识并实现推理的全过程寻找突破口,探索与人脑推理相类似的推理方法,这将对解决目前知识推

理对大规模训练数据的依赖问题以及提高推理速度有极大帮助。

5.3 前景展望

知识推理作为知识图谱的一个分支,是人工智能领域的重要组成部分,除了能够应用于智能问答、深度搜索、个性化推荐以及辅助决策等领域,也将在未来人工智能体的研究中充当重要一环。形式化地说,若将知识图谱比作智能体的大脑,那么知识推理则是使智能体实现知识应用并能够与客观世界交互的关键技术之一。

当然,知识推理的实现和应用具有很大的技术难度,距离发展成熟还有很长的路要走。目前,国内外致力于知识推理的研究呈现逐年上升的趋势,并且不断取得新的成果,当下的主流方法通常包括规则、逻辑等传统方法以及机器学习、深度学习等新方法。当下,知识图谱领域仍处于探索阶段,学术界对其尚无统一的定义,并且在研究过程中缺乏经典实用的典型方法与开源可靠的应用工具,这些因素也一定程度上影响了知识推理的研究进程。但是即便如此,知识推理在知识图谱补全与降噪中发挥的积极作用不言而喻,知识推理技术的发展将极大推动知识图谱补全与降噪效果的提升,间接促进知识图谱构建技术的逐步完善,因此,在知识图谱领域欣欣向荣的发展过程中,知识推理研究意义重大。

参考文献:

- [1] Bollacker K, Evans C, Paritosh P, et al. Freebase: a collaboratively created graph database for structuring human knowledge[C]//Proceedings of the 2008 ACM SIGMOD International Conference on Management of Data. New York: ACM, 2008: 1247-1250.
- [2] Auer S, Bizer C, Kobilarov G, et al. DBpedia: a nucleus for a web of open data[C]//Proceedings of the 6th International Semantic Web Conference. Berlin, Heidelberg: Springer, 2007: 722-735.
- [3] 丁建辉, 贾维嘉. 知识图谱补全算法综述[J]. 信息通信技术, 2018(1): 57-62.
- [4] 官赛萍, 靳小龙, 贾岩涛, 等. 面向知识图谱的知识推理研究进展[J]. 软件学报, 2018, 29(10): 74-102.
- [5] Tari L. Knowledge inference[M]. New York: Springer, 2013.
- [6] Russell S J, Norvig P. Artificial intelligence: a modern approach[J]. Applied Mechanics & Materials, 2010, 263(5): 2829-2833.
- [7] Kompridis N. So we need something else for reason to mean[J]. International Journal of Philosophical Studies, 2000, 8(3): 271-295.
- [8] 漆桂林, 高桓, 吴天星. 知识图谱研究进展[J]. 情报工程, 2017, 3(1): 4-25.
- [9] 徐增林, 盛泳潘, 贺丽荣, 等. 知识图谱技术综述[J]. 电子科技大学学报, 2016, 45(4): 589-606.
- [10] 刘峤, 李杨, 段宏, 等. 知识图谱构建技术综述[J]. 计算机研究与发展, 2016, 53(3): 582-600.
- [11] Lao N, Cohen W W. Relational retrieval using a combination of path-constrained random walks[J]. Machine Learning, 2010, 81(1): 53-67.
- [12] Socher R, Chen D, Manning C D, et al. Reasoning with neural tensor networks for knowledge base completion[C]//Proceedings of Advances in Neural Information Processing Systems. Red Hook, NY: Curran Associates Inc, 2013: 926-934.
- [13] Chen Danqi, Socher R, Manning C D, et al. Learning new facts from knowledge bases with neural tensor networks and semantic word vectors[J]. Computer Science, 2013, 11(1): 392-399.
- [14] Bordes A, Usunier N, Garcia-Duran A, et al. Translating embeddings for modeling multi-relational data[C]//Proceedings of Advances in Neural Information Processing Systems. Red Hook, NY: Curran Associates Inc, 2013: 2787-2795.
- [15] Wang Z, Zhang J, Feng J, et al. Knowledge graph embedding by translating on hyperplanes[C]//Twenty-eighth AAAI Conference on Artificial Intelligence, 2014.
- [16] Lin Y, Liu Z, Sun M, et al. Learning entity and relation embeddings for knowledge graph completion[C]//Proceedings of AAAI. Menlo Park, CA: AAAI, 2015.
- [17] Shi B, Weninger T. ProjE: embedding projection for knowledge graph completion[C]//Proceedings of the 31st AAAI Conference on Artificial Intelligence, Menlo Park, CA, 2017: 1236-1242.
- [18] Xie Ruobing, Liu Z, Jia J, et al. Representation learning of knowledge graphs with entity descriptions[C]//Proceedings of the 30th AAAI Conference on Artificial Intelligence. Menlo Park, CA: AAAI, 2016: 2659-2665.
- [19] Tay Y, Tuan L A, Phan M C, et al. Multi-task neural network for non-discrete attribute prediction in knowledge graphs[C]//Proceedings of the 2017 ACM on Conference on Information and Knowledge Management, 2017: 1029-1038.
- [20] Shi B, Weninger T. Open-world knowledge graph completion[J]. Computer Science, 2017, 5(2): 22-31.
- [21] 王奋昊. 大规模知识图谱技术[J]. 中国计算机学会通讯, 2014, 3(10): 64-68.
- [22] Lukovnikov D, Fischer A, Lehmann J, et al. Neural network-based question answering over knowledge graphs on word and character level[C]//International World Wide Web Conference Committee (IW3C2), Perth, Australia, 2017.
- [23] Schlichtkrull M, Kipf T N, Bloem P, et al. Modeling relational data with graph convolutional networks[J]. arXiv preprint arXiv:1703.06103, 2017.

(下转第36页)

- [73] Huang Z, Cheng G, Wang H, et al. Building extraction from multi-source remote sensing images via deep deconvolution neural networks[C]//Proceedings of IEEE International Geoscience and Remote Sensing Symposium (IGARSS). Beijing: IEEE, 2016: 1835-1838.
- [74] Zhou Z, Li S. Peanut planting area change monitoring from remote sensing images based on deep learning[C]//Proceedings of 4th International Conference on Systems and Informatics (ICSAI). Hangzhou: IEEE, 2017: 1358-1362.
- [75] Lin J, Li X, Pan H. Aircraft recognition in remote sensing images based on deep learning[C]//Proceedings of 33rd Youth Academic Annual Conference of Chinese Association of Automation (YAC). Nanjing: IEEE, 2018: 895-899.
- [76] Zou Q, Ni L, Zhang T, et al. Deep learning based feature selection for remote sensing scene classification[J]. IEEE Geoscience and Remote Sensing Letters, 2015, 12(11): 2321-2325.
- [77] Yang X, Liu W, Tao D, et al. Multiview canonical correlation analysis networks for remote sensing image recognition[J]. IEEE Geoscience and Remote Sensing Letters, 2017, 14(10): 1855-1859.
- [78] Deng Z, Lei L, Sun H, et al. An enhanced deep convolutional neural network for densely packed objects detection in remote sensing images[C]//Proceedings of International Workshop on Remote Sensing with Intelligent Processing (RSIP). Shanghai: IEEE, 2017: 1-4.
- [79] Tong G, Li Y, Cao L, et al. A DBN for hyperspectral remote sensing image classification[C]//Proceedings of 12th IEEE Conference on Industrial Electronics and Applications (ICIEA). Siem Reap: IEEE, 2018: 1757-1762.
- [80] Tanase R, Datcu M, Randucanu D. A convolutional deep belief network for polarimetric SAR data feature extraction[C]//The Proceedings of IEEE International Geoscience and Remote Sensing Symposium (IGARSS). Beijing: IEEE, 2016: 7545-7548.
- [81] Lv F, Han M, Qiu T. Remote sensing image classification based on ensemble extreme learning machine with stacked autoencoder[J]. IEEE Access, 2017, 5: 9021-9031.
- [82] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[C]//Proceedings of the 25th International Conference on Neural Information Processing System, 2012: 1097-1105.
- [83] 肖艳秋, 杜江恒, 闻萌莎, 等. 基于颜色特征和改进支持向量机算法的交通标志检测与识别[J]. 轻工学报, 2018, 33(3): 57-65.
- [84] Xiong C, Wang C, Ma W, et al. A traffic sign detection algorithm based on deep convolutional neural network[C]//Proceedings of IEEE International Conference on Signal and Image Processing (ICSIP). Beijing: IEEE, 2016: 676-679.
- [85] Zuo Z, Yu K, Zhou Q, et al. Traffic signs detection based on faster R-CNN[C]//Proceedings of IEEE 37th International Conference on Distributed Computing Systems Workshops (ICDCSW). Atlanta: IEEE, 2017: 286-288.
- [86] Ciresan C, Meier U, Gambardella M, et al. Convolutional neural network committees for handwritten character classification[C]//Proceedings of International Conference on Document Analysis and Recognition. Beijing: IEEE, 2011: 1135-1139.
- [87] Wu C, Fan W, He Y, et al. Handwritten character recognition by alternately trained relaxation convolutional neural network[C]//Proceedings of 14th International Conference on Frontiers in Handwriting Recognition. Heraklion: IEEE, 2014: 291-296.
- (上接第19页)
- [24] Yang B, Yih W T, He X, et al. Embedding entities and relations for learning and inference in knowledge bases[C]//Proceedings of the International Conference on Learning Representations, 2015: 233-240.
- [25] Neelakantan A, Roth B, McCallum A. Compositional vector space models for knowledge base completion[J]. Computer Science, 2015: 1-16.
- [26] Lin Y, Liu Z, Sun M. Modeling relation paths for representation learning of knowledge bases[J]. arXiv preprint arXiv: 1506.00379, 2015.
- [27] Das R, Neelakantan A, Belanger D, et al. Chains of reasoning over entities, relations, and text using recurrent neural networks[C]//Conference of the European Chapter of the Association for Computational Linguistics, 2017.
- [28] Shen Y, Huang P S, Chang M W, et al. Modeling large-scale structured relationships with shared memory for knowledge base completion[C]//Proceedings of the 2nd Workshop on Representation Learning for NLP. ACL, 2017: 57-68.
- [29] Graves A, Wayne G, Reynolds M, et al. Hybrid computing using a neural network with dynamic external memory[J]. Nature, 2016, 538(7626): 471-476.
- [30] Greff K, Srivastava R K, Koutník J, et al. LSTM: a search space odyssey[J]. IEEE Transactions on Neural Networks & Learning Systems, 2016, 28(10): 2222-2232.
- [31] Gers F A, Schmidhuber E. LSTM recurrent networks learn simple context-free and context-sensitive languages[J]. IEEE Transactions on Neural Networks, 2001, 12(6): 1333-1340.
- [32] Wang Z, Chen T, Ren J, et al. Deep reasoning with knowledge graph for social relationship understanding[J]. arXiv preprint arXiv: 1807.00504, 2018.
- [33] Scarselli F, Gori M, Tsoi A C, et al. The graph neural network model[J]. IEEE Transactions on Neural Networks, 2009, 20(1): 61.
- [34] Ren S, He K, Girshick R, et al. Faster R-CNN: towards real-time object detection with region proposal networks[C]//International Conference on Neural Information Processing Systems, 2015.